




AI 보안 박사과정 논문지도 세미나 강의계획서

본 세미나는 AI 보안 전공 박사과정생의 논문 기획-작성-투고-리비전 전 과정을 주간 **SCI/SCIE** 논문 기반 세미나 형태로 지도하는 것을 목표로 한다.

장장묵 교수 복수 박사 (공학:정보보호 2005, 정치학:정치법학 2009)

수업 개요

본 세미나는 AI 보안 전공 박사과정생의 논문 기획-작성-투고-리비전 전 과정을 "주간 SCI/SCIE 논문 기반 세미나" 형태로 지도하는 것을 목표로 한다.
수업의 지식구성 비율은 AI 기본 원리·이론(약 70%)과 기술-의존 보안 이슈(약 30%)로 설계한다.

AI 기본 원리·이론

약 70%

모델·학습·일반화·추론·평가 프레임워크의 과학적 이해

기술-의존 보안 이슈

약 30%

위협모형-공격면-방어-검증-운영리스크

수업 형태 및 구성

수업 형태는 온라인 실시간 세미나(**Zoom**)이며, 매주 토요일 오후 시작, 총 **100분(50분+50분)**으로 운영한다.

1

전반 50분

교수 강의 / 핵심정리

2

후반 50분

학생 발표·토론·리뷰

수업자료(주교재)는 매주 제공되는 **SCI/SCIE** 해외저널 논문 **5편**으로 구성한다.

교수 프로필(표기 요구사항 준수): 강장목 교수 복수 박사 (공학:정보보호 **2005**, 정치학:정치법학 **2009**)

본 수업은 **최신 이론과 SCI/SCIE 논문**을 바탕으로 (i) AI 학습이론·모델링·일반화·최적화·표현학습, (ii) 대적(Adversarial) 위협·데이터/모델 오염·프라이버시 공격·모델 도난·에이전트/프롬프트 취약성·MLOps 공급망 리스크를 체계화한다.

수업 운영 및 참여 규정

온라인 수업은 줌(Zoom)으로 진행하며, 모든 수강생은 **안정적 통신 환경**에서 **카메라(화면) ON**, **마이크 OFF**를 기본으로 한다(발표·질의 시에만 마이크 ON).

카메라(화면) ON

모든 수강생은 수업 중 카메라를 항상 켜둔다.

마이크 OFF (기본)

발표·질의 시에만 마이크를 켜는다.

안정적 통신 환경

원활한 수업 참여를 위해 안정적인 인터넷 환경을 확보한다.

학습활동 2-트랙 운영

학습활동은 다음의 2-트랙으로 통합 운영한다.

📄 논문 트랙 (Research Track)

매주 5편 논문을 기반으로 다음을 구조화한다:

- 연구문제 (Problem formulation)
- 위협모형 (Threat model)
- 평가방법 (Evaluation protocol)
- 재현성 (Reproducibility)
- 한계/오픈문제 (Open problems)

🤖 AI 도구 트랙 (Tool Track)

모든 수강생은 유료 버전 AI 도구를 최소 1개 이상 구독·사용한다(텍스트 LLM, 멀티모달 생성, 에이전트형 개발도구/IDE, 비디오 생성, 데이터 분석 자동화 등 범주 무관). **교재 대신 비용이 발생하며, 학생은 자신의 사용경험(Worklog) 또는 AI를 활용해 획득한 지식/성과를 발표하여 집단 지식에 기여한다**(예: KCI/SCIE 논문 초안 작성 과정, 주제 도출, 실험자동화, 동영상 제작, 에이전트 파이프라인 구축 등).

보고서/과제(있는 경우) 제출용 이메일은 별도 공지한다. 수업 운영·평가 관련 문의는 수업 종료 후 이메일로 접수한다: mooknc@naver.co / honukang@gmail.com.

발표 중심 평가 및 성적 처리 기준

평가는 발표 기반(peer scoring 중심)으로 운영한다.

1

발표 점수 산정 방식

수업에 실제로 참여한 학생에 한하여, 발표 종료 후 각 수강생이 발표 점수를 과대(반장)에게 제출한다. 과대는 제출 점수를 종합(정규화/요약통계 등)하여 담당교수에게 익명으로 전달한다(개별 채점자의 식별 정보는 전달하지 않는다).

2

성적 부여 방식

최종 학점은 발표 점수 분포에 따라 **A+** ~ **F**까지 부여한다. 운영상 일반적으로 **C+** ~ **B** 범위를 중심으로 처리하되(학습활동·발표수준·특이사항 등 반영), 사정이 있는 경우 조정할 수 있다(예: 장기질병, 불가항력적 시간충돌 등).

불이익, 가산점 및 이의 제기 정책

1

불이익 및 가산점

- 발표를 하지 않거나 하지 못하는 경우 불이익이 발생한다(예: 하위등급 처리, 추가제기회 제한 등).
- 과대 등 수업운영을 자진 지원하는 경우(예: 채점 취합, 자료공유 지원, 세미나 진행보조) **가산점(일정 부분)**을 부여할 수 있다.

2

이의 제기 정책

운영상의 문의·이의는 수업 종료 후 이메일로 접수하되, 성적 처리 완료(확정) 이후에는 해당 기준에 대한 이의를 받지 않는다.

3

발표 일정 공지

다음 주부터 발표 리스트(발표자/주제/도구)를 확정하여 운영한다(과대가 일정표를 취합·공유).

주차별 강의 구성

각 주차는 (i) **AI 원리(70%)**: 모델·학습·일반화·추론·평가 프레임워크의 과학적 이해, (ii) **보안 이슈(30%)**: 위협모형-공격면-방어-검증-운영리스크로 구성한다. 아래 논문 패킷은 교수가 **URL(주로 DOI)**로 다운로드 후 수업 종료 뒤 공유하는 것을 전제로 한다.

주차별 세부 목차 및 SCI/SCIE 논문 패킷



Week 1: 딥러닝 패러다임 & ML 보안 분류학

AI 원리

딥러닝 패러다임, 학습-일반화-표현의 기초 정식화

보안 이슈

ML 시스템 생명주기 관점의 보증(assurance)·위협모형, 대적 ML·프라이버시 공격의 분류학

학습목표

- (a) DL 핵심 구성요소를 공통 언어로 정리
- (b) ML lifecycle assurance desiderata 정의
- (c) 대적·프라이버시 공격 분류학을 연구지도 템플릿으로 고정

논문 패킷 (5편)

- Yann LeCun et al., "Deep learning", *Nature*, 521(7553), 2015, pp. 436–444. [DOI](#)
- Rob Ashmore et al., "Assuring the Machine Learning Lifecycle: Desiderata, Methods, and Challenges", *ACM Computing Surveys*, 54(5), 2021, Article 111. [DOI](#)
- Anna L. Buczak et al., "A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection", *IEEE Communications Surveys & Tutorials*, 18(2), 2016, pp. 1153–1176. [DOI](#)
- Y. Wang et al., "Adversarial Attacks and Defenses in Machine Learning: A Survey", *IEEE Communications Surveys & Tutorials*, 25(4), 2023, pp. 2245–2298. [DOI](#)
- Maria Rigaki et al., "A Survey of Privacy Attacks in Machine Learning", *ACM Computing Surveys*, 56(4), 2023, Article 101. [DOI](#)

Week 2: 대규모 최적화 & 데이터 오염 위협

AI 원리

대규모 최적화(First/Second-order), 효율적 학습(압축·경량화)과 일반화

보안 이슈

데이터 오염(poisoning)·훈련 데이터 조작의 위협모형·평가규약

학습목표

- (a) 최적화-일반화의 병목 정량화
- (b) 효율화 기법의 정확도-비용 트레이드오프
- (c) poisoning/backdoor의 공격자 비용모형과 방어평가 설계

논문 패킷 (5편)

- Léon Bottou et al., "Optimization Methods for Large-Scale Machine Learning", *SIAM Review*, 60(2), 2018, pp. 223–311. [DOI](#)
- Gulzar Menghani, "Efficient Deep Learning: A Survey on Making Deep Learning Models Smaller, Faster, and Better", *ACM Computing Surveys*, 55(12), 2023, Article 257. [DOI](#)
- Zhipeng Tian et al., "A Comprehensive Survey on Poisoning Attacks and Countermeasures in Machine Learning", *ACM Computing Surveys*, 55(8), 2022, Article 167. [DOI](#)
- Antonio Cinà et al., "Training Data Poisoning Attacks and Defenses: A Systematic Review", *ACM Computing Surveys*, 56(2), 2023, Article 34. [DOI](#)
- Z. Jin et al., "A survey of backdoor attacks and defences: From deep neural networks to large language models", *Journal of Electronic Science and Technology*, 23(1), 2025, Article 100326. [DOI](#)

Week 3: 컴퓨터비전 표현학습 & 비전 대적공격

AI 원리

컴퓨터비전 표현학습(CNN→ViT), 멀티모달 정합(공간·언어 임베딩)

보안 이슈

비전 기반 대적공격(white-box/black-box), 2D/3D 안전성·강건성(robustness) 평가

학습목표

- (a) 비전 학습의 귀납편향(inductive bias) 해부
- (b) 멀티모달 Transformer의 구조·학습규약
- (c) 비전 대적평가 벤치마크/지표를 논문레벨로 재구성

논문 패킷 (5편)

- Yann LeCun et al., "Gradient-Based Learning Applied to Document Recognition", *Proceedings of the IEEE*, 86(11), 1998, pp. 2278–2324. [DOI](#)
- Apostolos Voulodimos et al., "Deep Learning for Computer Vision : A Brief Review", *Computational Intelligence and Neuroscience*, 2018, Article 7068349. [DOI](#)
- Y. Xu et al., "Multimodal Learning With Transformers: A Survey", *IEEE TPAMI*, 45(10), 2023, pp. 12113–12132. [DOI](#)
- Salman Khan et al., "Transformers in Vision: A Survey", *ACM Computing Surveys*, 54(10s), 2022, Article 200. [DOI](#)
- Z. Li et al., "A Survey of Robustness and Safety of 2D and 3D Deep Learning Models Against Adversarial Attacks", *ACM Computing Surveys*, 56(5), 2023, Article 117. [DOI](#)

Week 4: Transformer 변형 & NLP 대적공격·프라이버시

AI 원리

Transformer 변형(X-formers)과 효율화(근사주의·저랭크·커널화·스파스 어텐션)

보안 이슈

NLP 대적공격/방어, 프롬프트-ICL(in-context learning) 환경의 프라이버시 위험

학습목표

- (a) 어텐션 복잡도 병목의 수학적 해소기법 비교
- (b) NLP 강건성의 공격면-방어면 매핑
- (c) 프롬프트 입력(민감정보) 보호기법의 평가항목 정의

논문 패킷 (5편)

- Yi Tay et al., "Efficient Transformers: A Survey", *ACM Computing Surveys*, 55(6), 2022, Article 109. [DOI](#)
- Quentin Fournier et al., "A Practical Survey on Faster and Lighter Transformers", *ACM Computing Surveys*, 55(14s), 2023, Article 304. [DOI](#)
- Tianyang Lin et al., "A survey of transformers", *AI Open*, 3(1), 2022, pp. 111–132. [DOI](#)
- N. Goyal et al., "A Survey on Adversarial Defenses and Robustness in NLP", *ACM Computing Surveys*, 56(3), 2023, Article 62. [DOI](#)
- Kennedy Edemacu et al., "Privacy Preserving Prompt Engineering: A Survey", *ACM Computing Surveys*, 57(10), 2025, Article 255. [DOI](#)

Week 5: 자기지도학습·파운데이션 모델 & Poisoning/Backdoor

AI 원리

자기지도학습(Self-Supervised Learning)·표현학습·파운데이션 모델의 사전 학습 규약

보안 이슈

표현학습 단계에서의 poisoning/backdoor 삽입, 벤치마크 데이터 거버넌스와 탐지

학습목표

- (a) SSL 표준 문제정의(contrastive/masked/predictive) 정리
- (b) 비디오 SSL의 사전학습-전이학습 평가
- (c) poisoning/backdoor가 representation space에 미치는 영향 측정

논문 패킷 (5편)

- Yan Gui et al., "Self-Supervised Learning: Algorithms, Applications, and Future Trends", *IEEE TPAMI*, 46(11), 2024, pp. 9052–9071. [DOI](#)
- H. Ren et al., "A Comprehensive Survey on Self-Supervised Learning", *ACM Computing Surveys*, 58(1), 2025, Article 22. [DOI](#)
- Madeline Schiappa et al., "Self-Supervised Learning of Video Representations: A Survey", *ACM Computing Surveys*, 55(13s), 2023, Article 278. [DOI](#)
- Y. Wang et al., "A Survey of Poisoning Attacks and Defenses on Machine Learning", *ACM Computing Surveys*, 55(3), 2022, Article 50. [DOI](#)
- Z. Jin et al., "A survey of backdoor attacks and defences: From deep neural networks to large language models", *Journal of Electronic Science and Technology*, 23(1), 2025, Article 100326. [DOI](#)

Week 6: 확률생성모형(Diffusion/GAN) & 딥페이크 검출

AI 원리

확률생성모형(Score-based/Diffusion, GAN)과 샘플링·조건부 생성

보안 이슈

합성미디어(딥페이크) 공격면, 검출·신뢰성(reliability)·포렌식 관점의 평가

학습목표

- (a) diffusion의 수학적 정식화와 샘플링 알고리즘 비교
- (b) GAN 기반 생성과 위협모형 연결
- (c) deepfake 검출의 데이터편향·일반화·신뢰성 지표 설계

논문 패킷 (5편)

- Ling Yang et al., "Diffusion Models: A Comprehensive Survey of Methods and Applications", *ACM Computing Surveys*, 56(3), 2023, Article 65. [DOI](#)
- Ananya Högele et al., "Video Diffusion Models: A Survey", *ACM Computing Surveys*, 56(9), 2024, Article 209. [DOI](#)
- Tianqi Wang et al., "Generative Adversarial Networks in Computer Vision: A Survey and Taxonomy", *ACM Computing Surveys*, 54(2), 2021, Article 38. [DOI](#)
- Yisroel Mirsky et al., "The Creation and Detection of Deepfakes: A Survey", *ACM Computing Surveys*, 54(1), 2021, Article 7. [DOI](#)
- J. Wang et al., "Deepfake Detection: A Comprehensive Survey from the Reliability Perspective", *ACM Computing Surveys*, 57(2), 2024, Article 43. [DOI](#)

Week 7: LLM 학습·정렬·평가 & LLM 보안·프라이버시

AI 원리

대규모 언어모델(LLM) 학습·추론·정렬(alignment)·평가(evaluation) 프레임워크

보안 이슈

LLM 보안·프라이버시(데이터 추출, 프롬프트 기반 공격, 소프트웨어 보안 점검)

학습목표

- (a) LLM 평가 프로토콜(벤치마크/오염/재현성) 체계화
- (b) LLM 보안·프라이버시 위협면 지도화
- (c) "소프트웨어 보안-LLM" 인터페이스에서의 공격표면 정의

논문 패킷 (5편)

- J. Chang et al., "A Survey on Evaluation of Large Language Models", *ACM Computing Surveys*, 56(12), 2024, Article 253. [DOI](#)
- Ankur Das et al., "Security and Privacy Challenges of Large Language Models: A Survey", *ACM Computing Surveys*, 57(9), 2025, Article 203. [DOI](#)
- Mingzhe Yao et al., "A survey on large language model security and privacy: problems, methods, and opportunities", *AI Open*, 2024 (4), 2024. [DOI](#)
- Yongtao Yin et al., "A survey on multimodal large language models", *National Science Review*, 11(12), 2024, Article nwae403. [DOI](#)
- Shujun Li et al., "When Software Security Meets Large Language Models: A Survey", *IEEE/CAA Journal of Automatica Sinica*, 12(1), 2025. [DOI](#)

Week 8: RAG·프롬프팅 프레임워크 & 프롬프트 인젝션

AI 원리

Retrieval-Augmented Generation(RAG)·그래프 기반 RAG·프롬프팅 프레임워크

보안 이슈

프롬프트 인젝션(prompt injection)·간접 인젝션·의료/안전영역의 취약성, 에이전트형 파이프라인의 공격면

학습목표

- (a) RAG의 추론경로(검색-재순위-생성) 구조해부
- (b) 프롬프팅 구성요소와 공격면 일치화
- (c) prompt injection의 근본원인(root cause)과 방어정책 설계

논문 패킷 (5편)

- Shiyu Chen et al., "Graph Retrieval-Augmented Generation: A Survey", *ACM Computing Surveys*, 2025(in press). [DOI](#)
- Jianxiang Li et al., "Graph-Based Approaches and Functionalities in Retrieval-Augmented Generation: A Survey", *ACM Computing Surveys*, 2026(in press). [DOI](#)
- X. Liu et al., "Prompting Frameworks for Large Language Models", *ACM Computing Surveys*, 2026(in press). [DOI](#)
- Tianlei Geng et al., "Prompt Injection Attacks on Large Language Models: A Survey of Attack Methods, Root Causes, and Defense Strategies", *Computers, Materials & Continua*, 82(2), 2026, pp. 3785–3826. [DOI](#)
- P. Lee et al., "Generative Artificial Intelligence and Prompt Injection Vulnerability in Drug Information Provision by Large Language Models", *JAMA Network Open*, 8(4), 2025, e2512796. [DOI](#)

Week 9: 심층강화학습(DRL) & 사이버보안 적용·보상조작

AI 원리

심층강화학습(DRL) 알고리즘 계통(DQN/Policy gradient/Actor-Critic)과 검증·안전성

보안 이슈

사이버보안 적용(DRL for cyber defense), 보상조작(reward manipulation)·모델 취약성

학습목표

- (a) DRL 핵심 메커니즘을 수학적 관점으로 재정렬
- (b) 사이버 도메인에서의 상태·행동·보상 설계
- (c) DRL 검증/테스팅 기법을 논문 평가체계로 정형화

논문 패킷 (5편)

- Kai Arulkumaran et al., "Deep Reinforcement Learning: A Brief Survey", *IEEE Signal Processing Magazine*, 34(6), 2017, pp. 26–38. [DOI](#)
- B. R. Kiran et al., "Deep Reinforcement Learning for Autonomous Driving: A Survey", *IEEE TITS*, 23(6), 2022, pp. 4909–4926. [DOI](#)
- Ngoc-Tinh Nguyen et al., "Deep Reinforcement Learning for Cyber Security", *IEEE TNNLS*, 34(8), 2023, pp. 3779–3795. [DOI](#)
- Aditya Adawadkar et al., "Cyber-security and reinforcement learning — A brief survey", *Engineering Applications of Artificial Intelligence*, 114, 2022, Article 105116. [DOI](#)
- H. Yan et al., "Deep Reinforcement Learning Verification: A Survey", *ACM Computing Surveys*, 56(2), 2023, Article 27. [DOI](#)

Week 10: 연합학습(FL) & FL 위협·방어·정책

AI 원리

연합학습(Federated Learning)·집계(Aggregation)·개인화(Personalization)·강건성

보안 이슈

FL 위협(gradient leakage/poisoning/backdoor/privacy attacks)·방어·정책

학습목표

- (a) FL 구성요소(클라이언트·서버·집계·통신) 분해
- (b) 공격-방어-비용 트레이드오프 모델링
- (c) FL 프라이버시 공격과 정책경관을 연결

논문 패킷 (5편)

- M. Arbaoui et al., "Federated Learning Survey: A Multi-Level Taxonomy of Aggregation Techniques, Experimental Insights and Future Frontiers", *ACM Computing Surveys*, 57(2), 2024. [DOI](#)
- Viraaji Mothukuri et al., "A survey on security and privacy of federated learning", *Future Generation Computer Systems*, 115, 2021, pp. 619–640. [DOI](#)
- Nuria Rodríguez-Barroso et al., "Survey on federated learning threats: Concepts, taxonomy on attacks and defences, experimental study and challenges", *Information Fusion*, 90, 2023, pp. 148–173. [DOI](#)
- J. Zhao et al., "A Survey of Federated Learning Privacy Attacks, Defenses, Applications, and Policy Landscape", *ACM Computing Surveys*, 57(9), 2025, Article 230. [DOI](#)
- T. D. Nguyen et al., "Backdoor attacks and defenses in federated learning: Survey, challenges and future research directions", *Engineering Applications of Artificial Intelligence*, 127, 2024, Article 107166. [DOI](#)

Week 11: 차등프라이버시(DP) & 멤버십 추론 공격·방어

AI 원리

차등프라이버시(Differential Privacy)·예산(privacy budget)·DP-SGD 및 프라이버시 회계(accounting)

보안 이슈

멤버십 추론(membership inference)·방어기법·연합학습/LLM 환경에서의 실무적 한계

학습목표

- (a) DP의 수학적 정의와 실무 오해(misuse) 정리
- (b) MI 공격과 방어를 threat model로 분해
- (c) DP-효용-학습안정성 트레이드오프를 실험설계로 연결

논문 패킷 (5편)

- Alberto Blanco-Justicia et al., "A Critical Review on the Use (and Misuse) of Differential Privacy in Machine Learning", *ACM Computing Surveys*, 55(8), 2022, Article 166. [DOI](#)
- Jonathan Demelius et al., "Differential Privacy in Centralized Deep Learning: A Survey", *ACM Computing Surveys*, 57(9), 2025, Article 202. [DOI](#)
- Zizheng Pan et al., "Differential Privacy in Deep Learning: A Literature Survey", *Neurocomputing*, 2024, Article 128346. [DOI](#)
- Hongsheng Hu et al., "Membership inference attacks on machine learning: a survey", *ACM Computing Surveys*, 54(11s), 2022, Article 235. [DOI](#)
- Hongsheng Hu et al., "Defenses to Membership Inference Attacks: A Survey", *ACM Computing Surveys*, 56(7), 2023, Article 144. [DOI](#)

Week 12: 신경망 검증·정형방법 & 대적방어·XAI·강건성 트레이드오프

AI 원리

신경망 검증(verification)·추상화(abstraction)·정형방법(formal methods)·강건성 증명

보안 이슈

대적공격의 체계적 방어, XAI 공격면, 강건성-정확도-공정성(trade-off) 최소화 전략

학습목표

- (a) 검증 프레임워크의 가정/완전성/스케일링 병목 해부
- (b) 공격-방어-설명가능성의 결합 위협면 모델링
- (c) 강건성 트레이드오프를 논문 기여로 전환(새 지표/새 설정)

논문 패킷 (5편)

- Boudardara et al., "A Review of Abstraction Methods Toward Verifying Neural Networks", *ACM Computing Surveys*, 56(7), 2024, Article 151. [DOI](#)
- Sen Zhou et al., "Adversarial Attacks and Defenses in Deep Learning", *ACM Computing Surveys*, 55(3), 2022, Article 60. [DOI](#)
- G. Vadillo et al., "Adversarial machine learning attacks against explainable artificial intelligence: A review", *WIREs Data Mining and Knowledge Discovery*, 15(3), 2025, e1567. [DOI](#)
- Inaki Pérez et al., "Adversarial Robustness of Neural Networks from Lipschitz Regularization: A Survey", *ACM Computing Surveys*, 56(9), 2024, Article 197. [DOI](#)
- Chih-Hsiang Cheng et al., "The Triangular Trade-off between Robustness, Accuracy, and Fairness", *ACM Computing Surveys*, 56(10), 2024, Article 214. [DOI](#)



Week 13-15: AI 보안 원리와 모델 지식재산 보호

AI 원리 · 모델 IP · 모델 도난 · 워터마킹 · MLOps 보안 · 평가 재현성 · XAI — 논문 패킷 기반 박사과정 세미나



Week 13 — AI 원리: 모델 지식재산(IP)·모델 도난·모델 추출 위협

AI 원리: 모델 지식재산(IP)·모델 도난(model stealing)·모델 추출(model extraction) 위협
· 보안 이슈: 워터마킹/핑거프린팅, 방어가 성능·품질·유틸리티에 미치는 영향 평가.

□ 논문 패킷(5) — 학습목표

- (a) "공개 API/배포 모델"의 경제적·기술적 위협 정식화
- (b) 워터마킹을 실험설계(탐지율·위양성·품질저하)로 재정의
- (c) 생성모형(GAN/LLM)에서의 방어가능성 검토

Week 13 — 논문 패킷 (5편)

모델 도난 서베이

Daria Oliynyk et al., "I Know What You Trained Last Summer: A Survey on Stealing Machine Learning Models and Defences", **ACM Computing Surveys**, 56(1), 2023-06-01, Article 7, 35 pages. <https://doi.org/10.1145/3595292>

워터마킹·핑거프린팅 서베이

Y. Ye et al., "A Survey of Watermarking and Fingerprinting Techniques for Deep Learning Models", **ACM Computing Surveys**, 2024(??), 2024-??-??, Article TBD. <https://doi.org/10.1145/3773028>

DNN 워터마킹 기법

Feng Li et al., "Deep neural network watermarking: Techniques and challenges", **Neurocomputing**, 461, 2021-11-01, pp. 171–193. <https://doi.org/10.1016/j.neucom.2021.07.051>

ModelShield: 적응형 강건 워터마크

Kaiyi Pang et al., "ModelShield: Adaptive and Robust Watermark Against Model Extraction Attack", **IEEE Transactions on Information Forensics and Security**, 20, 2025-01-01, pp. 1767–1780. <https://doi.org/10.1109/TIFS.2025.3530691>

GAN 공격·방어 서베이

Cheng Zhang et al., "Generative Adversarial Networks: A Survey on Attack and Defense", **ACM Computing Surveys**, 56(4), 2023-11-10, Article g1, pp. 1–35. <https://doi.org/10.1145/3615336>

Week 14 — AI 원리: MLOps/DevOps·데이터/모델 파이프라인·모니터링·드리프트·사고대응

AI 원리: MLOps/DevOps·데이터/모델 파이프라인·모니터링·드리프트·사고대응. **보안 이슈:** ML 공급망(supply chain)·운영환경 공격면(모델 배포/업데이트/로그)·보증사례(assurance case) 작성.

□ 논문 패킷(5) — 학습목표

- (a) "연구용 실험"과 "운영용 ML 시스템" 평가격차 해소
- (b) MLOps 실천항목을 보안통제항목으로 매핑
- (c) 논문(학술)과 운영(산업) 레이어의 정합을 학위논문 기여로 정의



Week 14 — 논문 패킷 (5편)

MLOps 실천 다성악 리뷰

Bayram Eken et al., "A Multivocal Literature Review of MLOps Practices: Emerging Trends, Challenges, and Research Directions", **ACM Computing Surveys**, 57(7), 2025-05-01, Article 162, 35 pages. <https://doi.org/10.1145/3747346>

ML 배포 도전과제 서베이

Andrei Paleyes et al., "Challenges in Deploying Machine Learning: A Survey of Case Studies", **ACM Computing Surveys**, 55(13), 2022-07-01, Article 274, 29 pages. <https://doi.org/10.1145/3533378>

MLOps·AIOps 체계적 서베이

Daniel Diaz-de-Arcaya et al., "A Systematic Survey on MLOps and AIOps: Taxonomy, Challenges, and Future Directions", **ACM Computing Surveys**, 57(1), 2023-11-01, Article 17, 36 pages. <https://doi.org/10.1145/3625289>

엣지 컴퓨팅 딥러닝 리뷰

J. Chen et al., "Deep Learning with Edge Computing: A Review", **Proceedings of the IEEE**, 107(8), 2019-08-01, pp. 1655-1674. <https://doi.org/10.1109/JPROC.2019.2921977>

소프트웨어 공학 딥러닝 서베이

Xiang Chen et al., "Deep Learning for Software Engineering: A Survey", **ACM Computing Surveys**, 54(8), 2022-01-01, Article 151, 36 pages. <https://doi.org/10.1145/3505243>

Week 15 — AI 원리: 연구평가·재현성·설명가능성(XAI)·논문 구성

AI 원리: 연구평가(evaluation)·재현성·설명가능성(XAI)·논문 구성(기여/한계/리비전 전략). **보안 이슈:** "평가 오염(benchmark contamination)–모델 유출–정책/윤리"를 포함한 종합 리스크.

□ 논문 패킷(5) — 학습목표

- (a) 박사논문/저널 논문 평가항목을 체크리스트화
- (b) XAI를 보안 관점(공격/오용)으로 재해석
- (c) 학기 종료 시점에 각자의 "논문 기여(Contribution)"를 1-2문장으로 고정



Week 15 — 논문 패킷 (5편)

LLM 평가 서베이

J. Chang et al., "A Survey on Evaluation of Large Language Models", **ACM Computing Surveys**, 56(12), 2024-08-01, Article 253, 42 pages. <https://doi.org/10.1145/3641289>

ML 라이프사이클 보증

R. Ashmore et al., "Assuring the Machine Learning Lifecycle: Desiderata, Methods, and Challenges", **ACM Computing Surveys**, 54(5), 2021-05-01, Article 111, pp. 1–39. <https://doi.org/10.1145/3453444>

설명가능 AI 핵심 아이디어

Vivek Dwivedi et al., "Explainable AI: Core Ideas, Techniques, and Solutions", **ACM Computing Surveys**, 56(9), 2023-04-01, Article 175, 39 pages. <https://doi.org/10.1145/3561048>

XAI 개념·분류·기회·도전

A. B. Arrieta et al., "Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI", **Information Fusion**, 58, 2020-06-01, pp. 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>

개념 기반 XAI 서베이

K. D. et al., "Concept-based Explainable Artificial Intelligence: A Survey", **ACM Computing Surveys**, 2025(in press), 2025-??-??. <https://doi.org/10.1145/3774643>

PPT 구성안

PPT는 "정책(운영/평가)"과 "주차별 목차"를 중심으로 **1슬라이드=1메시지** 구조로 작성한다(권장: 20-30장).

표지

과목명, 교수 프로필(요구된 표기), 운영형태(토요일·100분·온라인)

운영 규정

Zoom 참여규정(카메라 ON/마이크 OFF), 토론 규칙

교재/보조교재

매주 SCI/SCIE 논문 5편, 유료 AI 도구 구독 의무

평가

발표 중심·익명 집계·가산점·불이익·이의정책·연락처

주차별 목차

Week 1~15(각 주차 1장) — AI 원리 70% / 보안 이슈 30% / 논문패킷 5편(DOI)

부록

모의실험(데이터 오염·백도어) 결과 요약, 연구기여 포인트 표

모의실험 기반 실습 설계 — 오픈데이터 및 재현환경

본 강의의 실습은 "학술 논문 재현성"을 핵심 기준으로 설계한다. 최소 재현 실험은 공개 데이터 + 공개 라이브러리만으로 구성한다.

예시 오픈데이터(다운로드 가능)

UCI Optical Recognition of Handwritten Digits 데이터셋(8×8 표현 및 전처리 설명 포함).

<https://archive.ics.uci.edu/ml/datasets/optical+recognition+of+handwritten+digits>

최소 재현 파이프라인

실습용 최소 재현 파이프라인은 scikit-learn의 `load_digits()`(UCI digit s test set 복제본)로 즉시 구동 가능.

- 총 1797샘플
- 8×8 이미지 = 64차원
- 픽셀값 0-16

모의실험 결과 — 데이터오염 및 백도어 삽입

아래는 동일 데이터/모델에서 데이터오염(poisoning) 및 백도어(backdoor) 삽입의 효과를 수치로 확인하기 위한 모의실험 결과이다(로지스틱 회귀 기반 분류기).

라벨 플리핑(label-flipping) 오염

0.9778

정상 학습

클린 데이터 테스트 정확도

0.9267

5% 오염

라벨 플리핑 5% 적용

0.9000

10% 오염

라벨 플리핑 10% 적용

0.8933

20% 오염

라벨 플리핑 20% 적용

백도어 공격 결과

트리거=하단 우측 2x2 픽셀 고정, 타겟 라벨=0, 훈련데이터 5% 중독

0.9756

클린 테스트 정확도

거의 유지됨(stealth)

0.9531

공격 성공률(ASR)

트리거 삽입 샘플 대상

❏ 이 결과는 클린 정확도 저하가 작아도(backdoor stealth), 트리거 조건부 오분류가 매우 크게 나타날 수 있음을 보여주며, "학기 중 논문지도"에서 공격/방어 실험을 설계할 때 (i) 클린 성능, (ii) 공격 성공률, (iii) 탐지회피성을 함께 보고해야 함을 시사한다. (데이터셋 특성은 UCI/Scikit-learn 문서 기반)

실습 소프트웨어 개발 절차 및 커서 AI 프롬프트 시나리오

실습용 소프트웨어는 **요구사항-아키텍처-모듈화-테스트-재현성 패키징** 순서로 개발한다(권장: 반복적 증분개발).

기능·모듈 분해(예시)

DataModule 데이터 로딩, 전처리, 분할, 시드 고정, 메타데이터 기록	ModelModule 모델 정의(선형/심층), 학습루프, 체크포인트, 하이퍼파라미터 관리
AttackModule label-flip poisoning, backdoor trigger injection, (선택) adversarial example 생성	DefenseModule 데이터 정제, 이상치 탐지, 강건 학습(예: 정규화, 앙상블, 트리거 스캐닝)
EvaluationModule clean accuracy, ASR, confusion matrix, calibration(ECE), 실행시간, 리소스	ReproModule 실험설정 YAML, 결과 JSON, seed logging, 환경 정보(pip freeze)
ReportModule 표/그림 자동생성, 논문용 결과 서술 템플릿(LaTeX/Markdown) 출력	

커서 AI 프롬프트 입력 시나리오

아래는 'Cursor류 IDE 코딩 에이전트'에 단계적으로 투입하기 위한 프롬프트 시퀀스(요약형)이다.

01

요구사항

"digits 데이터 기반으로 clean 학습 + label-flip poisoning + backdoor 실험이 가능한 재현성 프로젝트를 Python 패키지 구조로 scaffold 해라. seed 고정, config YAML, 결과 JSON 저장을 필수로."

02

아키텍처

"DataModule/ModelModule/AttackModule/EvaluationModule을 인터페이스 중심으로 설계하고, 각 모듈의 public API와 타입힌트를 먼저 작성해라."

03

공격 모듈

"label-flip, backdoor(trigger injection) 구현하고, ASR을 계산하는 함수를 포함해라. 단위테스트를 추가해라."

04

실험 러너

"config를 읽어 다중 실험(오염물 sweep)을 돌리고, 결과를 csv/json으로 저장하며, 실행 로그를 남겨라."

05

리포트

"결과 csv/json에서 표와 그래프를 자동생성하고, 논문 결과 섹션 초안(예: Experimental Setup, Threat Model, Results)을 Markdown으로 생성해라."

06

확장

"동일 파이프라인을 텍스트/LLM 보안(프롬프트 인젝션 사례 실험)으로 확장 가능한 플러그인 구조로 리팩터링해라."

참고문헌 비교표와 연구 기여 포인트

핵심 연구축 비교표

아래 표는 본 강의가 사용하는 대표적 "연구축"을 공격면-방어면-평가면-운영면으로 정렬하고, 매핑 가능한 대표 서베이/리뷰를 연결한 것이다(강의 내 논문패킷 기반).

연구축	공격면(대표)	방어면(대표)	평가 핵심지표(예)	대표 참고
Lifecycle assurance	데이터→학습→배포 전 단계 취약	assurance case, 모니터링	요구사항 충족·드리프트 탐지	Ashmore et al.(2021)
Adversarial ML	evasion, transfer, adaptive attack	adversarial training, detection	robust acc, attack success	Wang et al.(2023)
Data poisoning/backdoor	label-flip, trigger insertion	cleansing, robust aggregation	clean acc + ASR + stealth	Tian et al.(2022)
Deepfakes	합성미디어 조작/허위증거	검출·포렌식·신뢰성	FPR/FNR, cross-dataset gen.	Mirsky et al.(2021)
LLM evaluation	벤치마크 오염, hidden test leakage	평가 프로토콜/데이터 위생	contamination, reproducibility	Chang et al.(2024)
Federated learning security	gradient leakage, poisoning, backdoor	secure aggregation, defense taxonomy	privacy leakage, robustness	Mothukuri et al.(2021)
Differential privacy	training-data leakage, MI	DP-SGD, accounting	ϵ -utility trade-off	Blanco-Justicia et al.(2022)
Model IP protection	model stealing/extraction	watermark/fingerprint	utility loss, detectability	Oliynyk et al.(2023)
MLOps security	supply chain, drift, logging risk	pipeline control, monitoring	MTTR, drift metrics	Eken et al.(2025)

부족한 부분과 박사과정 기여 포인트

주관 서베이들을 종합하면, 박사과정 논문 기여(Contribution)는 다음의 "연결부(connective tissue)"에서 만들어지기 쉽다.

평가 프로토콜의 과학화

LLM/RAG/Agent 보안 연구는 "공격 성공"만으로는 부족하며, (i) 데이터·프롬프트 오염 분리, (ii) 재현가능 seed / 환경, (iii) 오탐/미탐·비용·품질(utility) 포함된 다목적 평가가 필요하다. 이는 LLM 평가 서베이와 보안 서베이를 **동일 평가체제로 접합**하는 연구로 이어질 수 있다.

운영(MLOps)과 공격면의 정합

실전은 모델 그 자체보다 **배포 라이프라인/권한/로그/업데이트**에서 사고가 발생한다. 보안 연구를 "학습 알고리즘"에만 두지 말고, assurance/MLOps 서베이와 공격 서베이를 결합해 **운영-지향 위협모형**을 제안하면 공헌 점이 명확해진다.

증명가능한 강건성(verification) 스케일링

정형검증은 대규모 모델에서 병목이 크므로, 추상화/검증 서베이가 지적하는 병목을 직접 겨냥한 **"부분검증/위험기반검증"** 연구가 유효하다.

프롬프트/에이전트 입력의 프라이버시

프롬프트가 민감정보를 포함하는 현실에서, "프롬프트 보안(privacy-preserving prompting)"은 **DP와 다른 위협모형**을 요구한다. 프롬프트 보호 서베이를 기반으로, 특정 도메인(의료·금융·국방)의 데이터 규정과 연결한 실증 연구가 가능하다.